

KASTAMONU ÜNİVERSİTESİ
FEN BİLİMLERİ ENSTİTÜSÜ

BİLGİSAYAR MÜHENDİSLİĞİ ANABİLİM DALI



Çalışma ADI

Vertebral Column Classification: Deneyler ve Sonuçlar

1. Final Ödev raporu

Ad Soyad

Danışmanı:

Doç. Dr. Kemal AKYOL

KASTAMONU- 2025

(18 HAZİRAN 2025)

1. Giriş

Çalışmada, incelenmesi için verilen makalenin deneysel olarak insan omurgası ve pelvisinden fiziksel veriler içeren bir veri seti kullanılarak omurganın sağlıklı veya anormal olup olmadığını belirlemek amacıyla sınıflandırma modelleri geliştirilmesini kapsamaktadır. Veri seti Kaggle'den temin edilmiştir ve 310 örnek ile 13 özellik içermektedir. Veri setinin testi için üç model olarak Yapay Sinir Ağı (MLPClassifier), CART (DecisionTreeClassifier), CatBoostClassifier modelleri seçilmiştir. Çalışma Doğruluk, Duyarlılık ve Karışıklık Matrisi gibi parametreler dışında McNemar Testi P-değerlerini de barındırmaktadır.

2. Veri Seti

Örnek makalede açıklandığı gibi veri seti 12 sayısal özellik ve 1 kategorik hedef değişkenden oluşmaktadır. Özellikler insan omurgası ve pelvisine ilişkin fiziksel ölçümleri içermektedir. Hedef değişken omurganın sağlıklı (**Normal**) veya anormal (**Abnormal**) olduğunu göstermektedir[1]. Çalışma makine öğrenmesi seçilen modellerinin deneyler uygulanmıştır.

3. Yöntemler ve Deneyler

3.1. Literatür ve Modeller

Çalışmada aşağıdaki üç sınıflandırıcı model kullanılmıştır:

3.1.1. Yapay Sinir Ağı (MLPClassifier)

Yapay Sinir Ağı (YSA), biyolojik sinir sisteminden esinlenerek geliştirilen, veri öğrenme ve sınıflandırma yeteneğine sahip çok katmanlı yapay öğrenme sistemleridir [2]. Bu çalışmada kullanılan **MLPClassifier (Multi-layer Perceptron)**, en az bir gizli katmana sahip tam bağlantılı ileri beslemeli bir yapay sinir ağı modelidir. Girdi verilerinden karmaşık ilişkileri öğrenerek sınıflandırma problemlerine çözüm sunmaktadır. Vertebral sütun sınıflandırmasında MLPClassifier, insan omurgası ve pelvisine ilişkin fiziksel ölçümleri değerlendirerek omurganın normal ya da anormal durumunu öğrenir ve tahmin eder [3]. Literatürde, bu tür yapay sinir ağı modelleri, biyomekanik ölçümler üzerinden omurga anomalilerinin tespiti için başarıyla kullanılmıştır

3.1.2. CART (DecisionTreeClassifier)

Karar ağaçları (CART), veriyi dallar ve yapraklar şeklinde bölerek sınıflandırma işlemini gerçekleştiren denetimli öğrenme yöntemleridir [4]. DecisionTreeClassifier algoritması, insan omurgası ve pelvisine ilişkin fiziksel ölçümleri değerlendirerek omurganın normal ya da anormal durumunu öğrenir ve tahmin eder literatürde kullanımları bulunmaktadır.

3.1.3. CatBoostClassifier

CatBoost, Yandex tarafından geliştirilen ve özellikle kategorik verilerle etkili çalışan bir algoritmadır. Bu algoritma, overfitting riskini azaltmak ve tahmin performansını artırmak amacıyla sıralama tabanlı bilgi teorisi teknikleri kullanmaktadır [5]. İnsan omurgası ve pelvisine ilişkin fiziksel ölçümleri değerlendirerek omurganın normal ya da anormal durumunu öğrenir ve tahmin etmesini denemek adına seçilmiştir.

3.1.4. McNemar testi,

McNemar testi, iki sınıflandırma modelinin aynı veri kümesi üzerindeki tahmin başarılarını karşılaştırmak için kullanılan pratik bir istatistiksel yöntemdir. Özellikle "evet/hayır" gibi ikili sınıflandırma problemlerinde, modellerin doğru ve yanlış tahmin ettikleri örnekler arasında gerçekten anlamlı bir fark olup olmadığını değerlendirmek için tercih edilmiştir [6]. McNemar testi sonuçları ise, tüm model çiftleri arasında p-değerlerinin 0.05'in üzerinde olduğunu ve bu nedenle performans farklarının istatistiksel olarak anlamlı olmadığını ortaya koymaktadır.

3.2. Deney 1: Orijinal Veri Seti ile Temel Çalışma

Veri, sadece standart ölçeklendirme ile işlenmiştir. Model performansları doğrudan bu veri ile değerlendirilmiştir. Üç modelin doğruluk ve karışıklık matrisi sonuçlarına bakıldığında deney 1 için; CART modeli (**%85,48 doğruluk**) en yüksek performansı göstermektedir. Bu model hem yanlış pozitif beş tane hem de yanlış negatif dört tane sayısı bakımından en düşük hata oranına sahiptir. CatBoost modeli (**%83,87 doğruluk**) de yüksek bir başarı göstermiş olup, özellikle yanlış pozitif sayısı dört tane en düşük olan modeldir; ancak yanlış negatif sayısı altı tane biraz daha yüksektir. Yapay Sinir Ağı modeli (**%80,65 doğruluk**) ise doğru sınıflandırmada başarılı olmakla birlikte, özellikle yanlış pozitif sayısının yedi tane diğer modellere göre daha fazla olması dikkat çekmektedir. Genel olarak değerlendirildiğinde, CART modeli doğruluk oranı ve hata dağılımı açısından en dengeli ve etkili model olarak öne çıkmaktadır.

Deney 1 kapsamında yapılan McNemar test sonuçları, modeller arasında elde edilen farkların istatistiksel olarak anlamlı olmadığını söylemektedir. Yapay Sinir Ağı ile CART arasındaki p-değeri 0.5465, Yapay Sinir Ağı ile CatBoost arasındaki p-değeri 0.7237 ve CART ile CatBoost arasındaki p-değeri ise 1.0000 olarak bulunmuştur. Tüm bu değerler 0.05 anlamlılık eşiğinin üzerinde kaldığından, modellerin sınıflandırma başarıları arasında anlamlı bir fark olmadığı sonucuna varılmaktadır. Bu da uygulanan modellerin farklı algoritmik yapılara sahip olmasına rağmen, ham veri kullanıldığında benzer sınıflandırma yeteneklerine sahip olduğunu göstermektedir. Özellikle CART ve CatBoost modelleri arasında nerede ise farkın çok az olduğunu, bu iki modelin çıktılarının büyük ölçüde benzediğini göstermektedir. Yapay Sinir Ağı'nın doğruluğu biraz daha düşük olsa da elde edilen p-değerleri bu farkların rastlantısal olabileceğini yapay zeka destekli olarak işaret etmektedir. Bu nedenle, model seçimi yapılırken sadece doğruluk oranına değil, veri kümesinin yapısına, modelin yorumlanabilirliğine ve işlem maliyetine de dikkat edilmeden model denemesi olarak çalışıldığı unutulmamalıdır.

3.3. Deney 2: SMOTE + Recursive Feature Elimination (RFE)


Deney 2'de SMOTE ile veri dengesizliği giderildikten ve Recursive Feature Elimination (RFE) ile önemli özellikler seçildikten sonra modellerin performansları birbirine yakın olmakla birlikte, doğruluk oranlarında küçük farklılıklar gözlenmiştir. CatBoost, **%82,26 doğrulukla** en iyi sonucu verirken, Yapay Sinir Ağı ve CART modelleri **%79,03 doğrulukla** benzer performans göstermiştir. Karışıklık matrisleri incelendiğinde, CatBoost'un yanlış sınıflandırmaları biraz daha az olduğu dikkat çekmektedir. Ayrıca Yapay Sinir Ağı modelinde optimizasyonun tam olarak gerçekleşmediğine dair uyarı gözlenmiş, bu da modelin daha iyi ayarlanması gerektiğini işaret etmektedir. Genel olarak, SMOTE + RFE uygulaması modellerin dengeli performans sergilemesini sağlamış ve anlamlı bir üstünlük ortaya konmaya çalışılmıştır.

3.4. Deney 3: RFE + SMOTE

Deney 3'te, önce Recursive Feature Elimination (RFE) ile özellik seçimi yapılmış, ardından SMOTE ile sınıf dengesizliği giderilmiştir. Modeller Sinir Ağı, CART ve CatBoost için aynı doğruluk oranı olan **%83,87** değerini elde etmiş ve karışıklık matrisleri de tamamen örtüşmüştür. Bu durum, modellerin bu ön işleme kombinasyonu ile benzer performans sergilediğini göstermektedir. Genel olarak, RFE + SMOTE kombinasyonu modellerin performansını eşitlemiş ve anlamlı bir üstünlük sağlamıştır. Deney 2'ye göre daha başarılı olduğu da söylemek mümkündür.

4. Sonular

4.1. Doğruluk Oranları




Grafik-1: Doğruluk Karşılaştırması

Tablo-1: Deneylerin Sayısal Sonuçları


Deney	Yapay Sinir Ağı	CART	CatBoost
Deney 1	0.8065	0.8548	0.8387
Deney 2	0.7903	0.7903	0.8226
Deney 3	0.8387	0.8387	0.8387

Tablo-1’de genel olarak bakıldığında, CatBoost modelinin her üç deneyde de istikrarlı olduğu görölmektedir. Deney 1’de en yüksek doğruluk CART modelinde görünürken, Deney 2’de CatBoost öne çıkması ile CART’ın %8,17 bir farkla gerilediğini gözler önüne sermiştir. Deney 3’te ise tüm modeller eşit doğruluk göstermiştir. Bu durum, özellikle CatBoost’un farklı veri ön işleme adımlarına karşı daha dayanıklı ve tutarlı olduğunu göstermektedir.


4.2. Karışıklık Matrisi



Görsel-1: Deney 1 için Karmaşıklık Matrisi



Görsel-2: Deney 2 için Karmaşıklık Matrisi



Görsel-3: Deney 3 için Karmaşıklık Matrisi

5. Tartışma

Bu projede yapılan üç deney sonucunda CatBoost modeli genel olarak en iyi doğruluk oranlarını elde etmek için doğru model olabileceği kanısına varılmıştır. Özellikle deney 2 (SMOTE + RFE) aşamasında, doğruluk oranları diğer modellere göre bir miktar daha yüksek çıkması da bunu kanıtlar niteliktedir. Bu çalışma için, veri dengesizliğini gidermenin ve önemli özellikleri seçmenin model başarısını artırabileceğini mevcut çalışmada da değinilmiş olsa da seçilen modeller ve kullanılan modeller içinde de aynen geçerli olduğu düşünülmektedir.

Ancak, yapılan McNemar testleri sonucunda elde edilen p-değerleri 0.05'ten büyük olduğu için, modeller arasındaki farkların istatistiksel olarak anlamlı olmadığı söylenmektedir. Yani, elde edilen farklar rastlantısal olmaktadır. Bu nedenle, daha net sonuçlar elde edebilmek için daha büyük veri setleriyle ve farklı yöntemlerle çalışmalar yapılması ve proje takvimi için daha uzun bir zaman verilmesi de doğru olacaktır.

6. Sonuç

Üç Ayrı deneyli bu çalışma, vertebral sınıflandırma için farklı ön işleme teknikleri ve üç farklı sınıflandırma modeli karşılaştırılmıştır. CatBoost modeli ve SMOTE + RFE kombinasyonu, doğruluk bazında en iyi sonuçları vermiştir. Ancak modeller arasında istatistiksel olarak anlamlı fark olmadığı yapay zeka görüşü alınarak da doğrulanmıştır. Önerileri veri için uygun normalizasyon adımlarının yapılarak doğru modellerin seçilmesini söylemektedir. İlerisi için farklı veri ön işleme teknikleri, hiperparametre optimizasyonları ve daha geniş veri setleri ile çalışılması önerilmektedir. Gelecek vadeden bir çalışma için ise zamanı projenin iyiliğine yönelik olur ise literatürde güzel bir çalışma olarak yer alacağı düşünülmektedir.

KAYNAK

- [1]
- [2] Goodfellow, I. (2016). Deep learning.
- [3] Saravanakumar, D., & Reddy, R. (2020). A high performance asynchronous EOG speller system. *Biomedical Signal Processing and Control*, 59, 101898.
- [4] Breiman, L., Friedman, J., Olshen, R. A., & Stone, C. J. (2017). *Classification and regression trees*. Routledge.
- [5] Dorogush, A. V., Ershov, V., & Gulin, A. (1810). CatBoost: Gradient boosting with categorical features support. arXiv 2018. *arXiv preprint arXiv:1810.11363*.
- [6] McNemar, Q. (1947). Note on the sampling error of the difference between correlated proportions or percentages. *Psychometrika*, 12(2), 153-157.

